

Laporan Tugas Scraping dan EDA

Analisis Performa dan Salary Pemain MLB

1. Deskripsi Dataset

Dataset *mlb_player_value* memuat **2.673 observasi pemain-musim** pada musim 2022-2025, dengan 48 kolom awal dan 1.052 Player_ID unik. Satu pemain dapat muncul pada beberapa musim; karena itu, jumlah baris tidak sama dengan jumlah pemain unik. Dataset memenuhi batas minimal 1.500 baris dan 5 fitur pada tugas praktikum.

EDA berfokus pada distribusi usia dan gaji, hubungan performa dengan gaji, tren median gaji menurut posisi, serta penyaringan kandidat *undervalued*. Notebook memuat pembacaan CSV dan eksplorasi; kode maupun rincian sumber scraping tidak disertakan sehingga proses pengambilannya tidak dapat dijelaskan dari notebook ini.

Tabel 1. Kelompok atribut dan jenis datanya.

Jenis atribut	Kolom / keterangan
Nominal (11 kolom)	Player, Player_ID (identitas, meskipun bertipe integer), Player_URL, Team, Lg, Pos, _nk, Player_sal, Team_sal, Pos_sal, merge_flag.
Ordinal (1 kolom)	Age_Group: kelompok usia yang memiliki urutan.
Numerik diskrit (17 kolom)	Season, Age, G, PA, AB, R, H, 2B, 3B, HR, RBI, SB, BB, SO, HBP, SF, numTeams. Season adalah indeks waktu tahunan.
Numerik kontinu (19 kolom)	BA, OBP, SLG, OPS, OPS+, Salary, Salary_cash, Salary_payroll, lgOBP, lgSLG, OPS+_est, HR_Rate, BB_Rate, SO_Rate, RBI_per_Game, HR_per_Million, RBI_per_Million, OPS_per_Million, Salary_per_HR.

PA menunjukkan jumlah *plate appearances* (kesempatan tampil memukul), HR adalah *home run*, dan RBI adalah *runs batted in*. OPS menggabungkan OBP dan SLG. Dalam CSV ini, seluruh nilai OPS+ identik dengan OPS+_est; analisis menggunakan kolom tersebut sebagaimana di notebook, tanpa memverifikasi kesetaraannya dengan OPS+ resmi.

2. Statistik Deskriptif

Tabel 2. Ringkasan atribut utama; Salary dalam juta USD.

Atribut	Min	Maks	Mean	Median	Std. dev.
Age	19	42	27,73	27	3,66
PA	1	753	273,67	230	216,96
HR	0	62	8,30	5	9,45
RBI	0	144	30,87	23	28,85
OPS+	-100	567	78,90	85,90	55,10
Salary	0,70	70,00	3,99	0,76	6,99

Statistik performa dan usia memakai 2.673 baris; Salary memakai 2.505 nilai tersedia. Mean Salary jauh di atas mediannya, konsisten dengan distribusi miring ke kanan. Angka OPS+ pada tabel mencakup semua PA, berbeda dengan histogram yang dibatasi $PA \geq 100$.

Secara kategorikal, posisi terbanyak adalah C (394 baris), diikuti RF (310), serta 2B dan 3B (masing-masing 306). Jumlah observasi per musim adalah 693 (2022), 656 (2023), 651 (2024), dan 673 (2025).


3. Penanganan Data

3.1. Nilai hilang (missing values)

Nilai hilang terkonsentrasi pada data gaji, atribut pasangan data gaji, dan rasio yang menggunakan gaji. Tabel berikut merangkum seluruh kolom dengan nilai hilang pada CSV awal.

Tabel 3. Jumlah dan persentase missing dari 2.673 baris.

Kolom	Jumlah missing	Persentase
Player_sal, Team_sal, Pos_sal, Salary, Salary_payroll, HR_per_Million, RBI_per_Million, OPS_per_Million	168 per kolom	6,29% per kolom
Salary_cash	200	7,48%
Salary_per_HR	644	24,09%
38 kolom lainnya	0	0,00%



Gambar 1. Korelasi kemunculan nilai hilang antar kolom, dari notebook.

Insight: Beberapa kolom memiliki pola kehilangan yang sangat berkaitan. Pola ini menunjukkan keterkaitan ketersediaan data, tetapi belum cukup untuk menetapkan mekanisme *missing not at random* (MNAR). Penyebab missing perlu ditelusuri dari sumber dan proses penggabungan data.

Penanganan yang benar-benar dilakukan adalah membuat **Salary_Missing**: bernilai 1 jika Salary kosong dan 0 jika tersedia. Notebook tidak mengimputasi gaji. Histogram Salary menggunakan nilai nonmissing; analisis OPS+-Salary dan kandidat *undervalued* memakai $PA \geq 100$ serta OPS+ dan Salary yang tersedia. Subset tersebut berisi 1.780 baris. Nilai kosong tetap dipertahankan pada dataset utama.


3.2. Nilai ekstrem dan outlier

Histogram Salary memperlihatkan ekor kanan panjang hingga 70 juta USD. Notebook mengamati nilai ekstrem secara visual, tanpa deteksi formal berbasis IQR atau z-score, dan tidak menghapus maupun melakukan *capping* pada nilai tersebut. Pada histogram tambahan, skala log diterapkan pada **frekuensi (sumbu y)**, bukan mengubah nilai Salary.

Median digunakan untuk tren gaji dan batas kuadran karena lebih tahan terhadap nilai ekstrem dibandingkan mean. Filter $PA \geq 100$ membatasi analisis OPS+ pada observasi dengan kesempatan tampil lebih banyak; filter ini bukan prosedur penghapusan outlier statistik. Tidak ada uji normalitas yang dijalankan di notebook.

4. Visualisasi dan Interpretasi


4.1. Distribusi usia dan gaji



Gambar 2. Kiri: histogram usia dengan KDE. Kanan: histogram Salary dalam juta USD.

Insight: Usia terkonsentrasi pada pertengahan hingga akhir 20-an, dengan mean 27,73 dan median 27 tahun. Observasi berusia di atas 35 tahun relatif sedikit. Bentuknya menyerupai lonceng, tetapi kenormalan tidak dapat disimpulkan hanya dari kesamaan atau perbedaan mean dan median. Gaji sangat miring ke kanan: banyak observasi berada pada gaji rendah, sementara sedikit nilai sangat tinggi menaikkan mean.


4.2. Distribusi OPS+ setelah filter PA



Gambar 3. Distribusi OPS+ pada 1.846 observasi dengan PA ≥ 100.

Insight: Distribusi terlihat lebih terpusat dibandingkan rentang OPS+ seluruh data yang mencapai -100 sampai 567. Garis 100 dipakai sebagai acuan pada notebook; garis tersebut bukan mean atau median sampel. Sebagian observasi berada di atas 100, sedangkan nilai pada kedua ekor tetap perlu dibaca dengan memperhatikan jumlah PA.

4.3. Tren median Salary berdasarkan posisi




Gambar 4. Median Salary per posisi dan musim; filter minimum 10 baris pada musim yang tercatat.

Insight: Median gaji tidak bergerak seragam antarposisi. DH menunjukkan perubahan mencolok: 1,40 juta USD (2022), 2,20 juta (2023), 0,75 juta (2024), dan 3,325 juta (2025). Jumlah DH per musim adalah 51, 48, 40, dan 47 baris, sedangkan yang memiliki Salary hanya 48, 43, 37, dan 45. Perubahan komposisi sampel perlu dipertimbangkan; tren ini bukan perubahan gaji kelompok pemain yang selalu sama.

4. Visualisasi dan Interpretasi (lanjutan)

4.4. Korelasi performa dan Salary




Gambar 5. Heatmap korelasi Pearson pada 12 atribut yang dipilih di notebook.

Insight: Korelasi Salary dengan HR sebesar **0,52**, RBI **0,50**, Age **0,41**, dan OPS+ **0,25**. Di antara atribut tersebut, HR dan RBI memiliki hubungan linear lebih kuat dengan gaji dibandingkan OPS+. HR dan RBI juga berkorelasi kuat satu sama lain (0,93), sehingga keduanya memuat informasi performa yang saling berkaitan.

Korelasi ini menunjukkan asosiasi, bukan bukti bahwa perubahan performa menyebabkan perubahan gaji. Heatmap menggunakan seluruh baris yang tersedia untuk setiap pasangan kolom; tidak diterapkan filter $PA \geq 100$ pada perhitungan tersebut.

4.5. Hubungan gaji dengan OPS+ dan home run




Gambar 6. Kiri: OPS+ vs Salary dengan $PA \geq 100$. Kanan: HR vs Salary tanpa filter PA.

Insight OPS+: Pada nilai OPS+ yang mirip, Salary dapat berbeda jauh. Observasi dengan performa tinggi juga muncul pada gaji rendah, sehingga OPS+ saja belum menjelaskan variasi gaji. Sebaran ini sejalan dengan korelasi positif yang relatif lemah pada heatmap, meskipun subset scatter plot berbeda.

Insight HR: Jumlah home run yang lebih besar cenderung beriringan dengan gaji lebih tinggi, tetapi variasinya tetap lebar. Ada observasi dengan HR tinggi bergaji rendah maupun HR rendah bergaji tinggi. Temuan ini mendukung penggunaan beberapa indikator saat membandingkan performa dan gaji, tanpa menyatakan HR sebagai satu-satunya penentu Salary.

4.6. Penyaringan kandidat undervalued



Gambar 7. Kuadran OPS+ dan Salary berdasarkan median pada subset analisis.

Notebook menggunakan 1.780 observasi dengan PA ≥ 100 dan nilai OPS+ serta Salary tersedia. Batas kuadrannya adalah median OPS+ **95,65** dan median Salary **0,8625 juta USD** (862.500 USD). Kandidat dipilih jika OPS+ **lebih besar** dari median dan Salary **lebih kecil** dari median; terdapat 366 observasi pemain-musim yang memenuhi aturan ini.

Insight: Kuadran kanan bawah memuat performa relatif tinggi dengan gaji relatif rendah terhadap subset ini. Median digunakan agar batas tidak terlalu dipengaruhi gaji ekstrem. Daftar diurutkan berdasarkan OPS+ menurun, lalu Salary menaik, sesuai notebook.

Tabel 4. Delapan kandidat teratas dari hasil penyaringan notebook.

Pemain	Musim	Pos	PA	OPS+	Salary (juta USD)
Yordan Alvarez	2022	DH	561	185,6	0,76460
Nick Kurtz	2025	1B	489	174,8	0,76000
Davis Schneider	2023	2B	141	171,8	0,72000
Alex Call	2024	RF	113	167,7	0,74000
Joey Meneses	2022	1B	240	160,4	0,70000
Jahmai Jones	2025	DH	150	159,0	0,81000
Brent Rooker	2024	DH	614	157,7	0,75000
Kerry Carpenter	2024	RF	296	157,6	0,76100

Istilah *undervalued* di sini merupakan hasil penyaringan relatif, bukan estimasi nilai pasar atau bukti salah harga kontrak. Ambang OPS+ 95,65 juga berbeda dari garis acuan 100. Variasi PA antarkandidat menunjukkan bahwa kekuatan bukti performa tidak sama; notebook belum mengevaluasi faktor kontrak atau keberlanjutan performa.

5. Kesimpulan

EDA menunjukkan bahwa usia pemain-musim terkonsentrasi di akhir 20-an, sementara Salary memiliki distribusi sangat miring ke kanan. HR dan RBI berkorelasi positif lebih kuat dengan Salary dibandingkan OPS+, tetapi sebaran gaji pada performa serupa tetap lebar. Tren median gaji antarposisi, khususnya DH, harus dibaca bersama jumlah observasinya.

Penanganan data dalam notebook terbatas pada pembuatan Salary_Missing, pemilihan nilai tersedia, dan filter PA untuk analisis tertentu; tidak dilakukan imputasi maupun penghapusan outlier formal. Penyaringan berbasis median menghasilkan kandidat bergaji relatif rendah dengan performa relatif tinggi, sebagai titik awal analisis lanjutan.

Sumber: EDA(2).ipynb dan mlb_player_value(3).csv. Struktur mengikuti PDF tugas praktikum; gaya tabel dan penyajian gambar mengacu pada laporan 5054251030_Raihan Nurhakim. Seluruh grafik diambil dari output notebook.