# ANALISIS ASSOCIATION RULE
# PADA DATASET ONLINE RETAIL

Pranaja Adyatma Budiman 5054251009

## 1 Pendahuluan

Dataset Online Retail berisi catatan transaksi penjualan yang setiap invoicenya dapat memuat lebih dari satu produk. Analisis ini menggunakan metode **association rule** untuk mengidentifikasi produk yang cenderung muncul secara bersamaan dalam satu invoice. Dengan demikian, unit analisis yang digunakan adalah transaksi, bukan pelanggan secara individual.

Tahapan analisis meliputi pemeriksaan dan pembersihan data, penghapusan invoice pembatalan serta kuantitas yang tidak valid, deduplikasi pasangan invoice-produk, dan pembentukan matriks transaksi. Matriks tersebut selanjutnya diproses menggunakan algoritma FP-Growth untuk memperoleh **frequent itemsets**. Hubungan antarproduk dievaluasi menggunakan metrik **support**, **confidence**, dan **lift**.

Analisis dibatasi pada kombinasi dengan panjang maksimum tiga produk (`max_len = 3`). Konfigurasi akhir menggunakan `min_support = 0.02` dan `min_confidence = 0.5`. Hasil yang dibahas merepresentasikan pola ko-kemunculan produk pada data historis, sehingga tidak dapat langsung ditafsirkan sebagai hubungan sebab-akibat atau bukti peningkatan penjualan.

## 2 Hasil dan Pembahasan

### 2.1 Struktur dan Karakteristik Dataset

Dataset awal memiliki 541.909 baris dan 8 kolom. Setiap baris merepresentasikan satu baris item di dalam invoice; satu invoice dapat memiliki beberapa baris produk.

| Kolom | Makna dalam konteks analisis | Peran |
|---|---|---|
| `InvoiceNo` | Nomor invoice atau identitas transaksi. | Kunci pembentukan basket |
| `StockCode` | Kode produk. | Identifikasi produk pada data sumber |
| `Description` | Nama atau deskripsi produk. | Item yang dianalisis |
| `Quantity` | Jumlah unit produk pada baris invoice. | Filter retur / kuantitas tidak valid |
| `InvoiceDate` | Tanggal dan waktu transaksi. | Informasi periode; tidak dipakai dalam aturan |
| `UnitPrice` | Harga per unit. | Tidak dipakai dalam pembentukan aturan |
| `CustomerID` | Identitas pelanggan. | Tidak dipakai karena analisis pada level invoice |
| `Country` | Negara transaksi. | Tidak dipakai dalam pembentukan aturan |

Periode transaksi yang tercatat berlangsung dari 1 Desember 2010 pukul 08.26 hingga 9 Desember 2011 pukul 12.50. Kolom `CustomerID` memiliki 135.080 nilai kosong atau 24,93%, sedangkan `Description` memiliki 1.454 nilai kosong atau 0,27%. Enam kolom lainnya tidak memiliki nilai kosong berdasarkan ringkasan notebook.

Nilai kosong pada `CustomerID` tidak menyebabkan baris otomatis dihapus. Keputusan ini konsisten dengan tujuan analisis: selama invoice dan deskripsi produk tersedia, item masih dapat dimasukkan ke dalam keranjang transaksi meskipun pelanggan tidak teridentifikasi.

## 2.2 Pembersihan dan Persiapan Data

Notebook menerapkan tiga kriteria utama untuk mengeluarkan baris:

1. `Description` kosong atau hanya berisi teks kosong.
2. Invoice dibatalkan, ditandai dengan `InvoiceNo` yang diawali huruf `C`.
3. `Quantity` bernilai nol atau negatif.

Spasi berlebih pada `Description` juga dinormalisasi agar variasi spasi tidak membuat deskripsi produk yang sama terbaca sebagai item berbeda.

| **Kriteria** | **Jumlah baris** |
|---|---|
| Deskripsi kosong | 1.454 |
| Invoice dibatalkan (`InvoiceNo` diawali `C`) | 9.288 |
| `Quantity <= 0` | 10.624 |
| **Gabungan baris yang dihapus** | **11.216** |

Jumlah pada masing-masing kriteria dapat saling tumpang tindih. Karena itu, angka 1.454, 9.288, dan 10.624 tidak boleh dijumlahkan untuk memperoleh total penghapusan. Total 11.216 adalah hasil gabungan baris yang memenuhi setidaknya satu kriteria.

Setelah pembersihan, jumlah baris berkurang dari 541.909 menjadi 530.693. Jumlah invoice unik berubah dari 25.900 menjadi 20.136. Dengan demikian, terdapat 5.764 invoice lebih sedikit pada data bersih. Pengurangan jumlah invoice tersebut penting diperhatikan karena analisis selanjutnya hanya menggunakan transaksi yang lolos proses penyaringan.

## 2.3 Deduplicasi dan Pembentukan Basket

Sebelum membentuk transaksi, notebook menghapus duplikasi berdasarkan pasangan `InvoiceNo` dan `Description`. Dengan pendekatan ini, satu nama produk hanya dihitung satu kali di dalam satu invoice, terlepas dari berapa unit produk tersebut tercatat pada baris invoice.

Dari 530.693 baris hasil pembersihan, sebanyak 10.857 baris duplikat pasangan invoice-produk dihapus. Hasil akhirnya terdiri dari 519.836 pasangan invoice-produk unik, 20.136 transaksi, dan 4.057 produk unik. Rata-rata terdapat 25,82 produk unik per invoice.

Transformasi tersebut menghasilkan matriks one-hot berukuran 20.136 transaksi × 4.057 produk. Setiap baris merepresentasikan satu invoice, sedangkan setiap kolom merepresentasikan satu produk. Dalam matriks ini, `True` berarti produk muncul pada invoice tertentu dan `False` berarti produk tidak muncul. Total nilai `True` adalah 519.836, sama dengan jumlah pasangan invoice-produk unik yang dibentuk sebelum transformasi.

## 2.4 Implikasi Keputusan Preprocessing

Pendekatan basket berbasis kehadiran produk sesuai untuk association rule karena yang diuji adalah apakah produk muncul dalam transaksi, bukan berapa unit yang dibeli. Konsekuensinya, informasi jumlah unit tidak lagi dibedakan setelah deduplikasi. Jika tujuan lanjutan adalah mempelajari kuantitas pembelian atau nilai keranjang, analisis tambahan perlu menggunakan `Quantity` dan `UnitPrice`.

Penggunaan `Description` sebagai identitas item juga berarti pengelompokan mengikuti nama produk, bukan kode `StockCode`. Hal ini membantu membaca aturan dalam bahasa produk, tetapi konsistensi penamaan deskripsi menjadi penting.

## 2.5 Metode FP-Growth dan Association Rule

**Alasan penggunaan FP-Growth.**

Notebook menggunakan algoritma FP-Growth untuk mencari frequent itemsets. Secara konseptual, FP-Growth membangun struktur pohon untuk memadatkan informasi transaksi sehingga pencarian pola tidak perlu membangkitkan kandidat itemset secara berulang seperti pendekatan Apriori. Algoritma tersebut diterapkan pada matriks one-hot hasil persiapan data.

**Metrik evaluasi aturan.**

Tiga metrik digunakan untuk menilai aturan berbentuk `X -> Y`, dengan `X` sebagai antecedent dan `Y` sebagai consequent.

- **Support** mengukur proporsi seluruh invoice yang memuat item pada sisi `X` dan `Y` secara bersamaan.
- **Confidence** mengukur proporsi invoice yang memuat `Y` di antara invoice yang sudah memuat `X`.
- **Lift** membandingkan confidence aturan dengan support consequent. Lift di atas 1 menunjukkan bahwa `Y` lebih sering muncul pada invoice yang memuat `X` dibandingkan dengan frekuensi kemunculan `Y` secara keseluruhan.

Secara matematis:

$$\text{Support}(X \to Y) = \frac{\text{count}(X \cup Y)}{N} \qquad \text{Confidence}(X \to Y) = \frac{\text{Support}(X \cup Y)}{\text{Support}(X)} \qquad \text{Lift}(X \to Y) = \frac{\text{Confidence}(X \to Y)}{\text{Support}(Y)}$$

`N` adalah jumlah seluruh invoice yang dianalisis. Jumlah invoice pada tabel aturan merupakan **support count**: banyaknya invoice yang memuat seluruh item di antecedent dan consequent secara bersamaan. Angka tersebut bukan jumlah invoice yang hanya memuat antecedent.

**Penentuan parameter.**

Konfigurasi awal dan final pada notebook dirangkum berikut.

| Konfigurasi | Min. support | Min. confidence | Max. length | Jumlah aturan |
|---|---|---|---|---|
| Awal | 0,01 | 0,50 | 3 | 741 |
| Final | 0,02 | 0,50 | 3 | 61 |

Pada 20.136 invoice, support 1% setara dengan sekitar 201 invoice, sedangkan support 2% setara dengan sekitar 403 invoice. Dengan menaikkan support, pola yang hanya muncul pada sebagian kecil transaksi tersaring lebih ketat. Confidence dipertahankan pada 0,5 agar batas kekuatan kondisional yang digunakan tidak berubah.

Konfigurasi awal menghasilkan 1.849 frequent itemsets: 804 itemset berisi satu produk, 822 itemset berisi dua produk, dan 223 itemset berisi tiga produk. Konfigurasi final menghasilkan 378 frequent itemsets dan 61 aturan. Dengan demikian, jumlah aturan berkurang sekitar 91,77% dibandingkan hasil awal, sehingga daftar akhir lebih praktis untuk diinterpretasikan.

### 2.6 Hasil Aturan Asosiasi

**Gambaran hasil akhir.** Pada konfigurasi final, terdapat 61 aturan asosiasi. Rentang lift berada pada 5,0768 hingga 18,5516 dan seluruh aturan memiliki lift lebih besar dari 1. Artinya, semua aturan yang lolos filter menunjukkan asosiasi positif menurut ukuran lift. Meski demikian, nilai lift tinggi tidak otomatis berarti jumlah invoice yang tercakup besar; support tetap perlu dibaca bersama lift dan confidence.

### 2.7 Aturan dengan Nilai Lift Tertinggi: Regency Teacup and Saucer

Tiga aturan dengan lift tertinggi berkaitan dengan kombinasi tiga varian produk: **Pink Regency Teacup and Saucer**, **Green Regency Teacup and Saucer**, dan **Roses Regency Teacup and Saucer**.

| Antecedent (jika) | Consequent (maka) | Invoice | Support | Confidence | Lift |
|---|---|---|---|---|---|
| Pink Regency Teacup and Saucer | Green + Roses Regency Teacup and Saucer | 542 | 2,69% | 70,76% | 18,5516 |
| Green + Roses Regency Teacup and Saucer | Pink Regency Teacup and Saucer | 542 | 2,69% | 70,57% | 18,5516 |
| Pink + Roses Regency Teacup and Saucer | Green Regency Teacup and Saucer | 542 | 2,69% | 90,48% | 17,9506 |

Interpretasinya:

- Aturan pertama menunjukkan bahwa dari invoice yang memuat varian **Pink**, sekitar 70,76% juga memuat kedua varian **Green** dan **Roses**. Kombinasi tiga produk tersebut muncul pada 542 invoice, setara dengan 2,69% seluruh invoice analisis.
- Aturan kedua menunjukkan arah sebaliknya: ketika varian **Green** dan **Roses** muncul bersama, 70,57% invoice juga memuat varian **Pink**.

- Aturan ketiga memiliki confidence 90,48%. Artinya, dari invoice yang memuat varian **Pink** dan **Roses**, sekitar 90,48% juga memuat varian **Green**.

Ketiga aturan tersebut bukan tiga temuan yang sepenuhnya independen. Semuanya merupakan arah aturan yang berbeda dari satu pola ko-kemunculan tiga varian dalam keluarga produk yang sama. Oleh sebab itu, insight utamanya bukan sekadar terdapat tiga aturan dengan lift tinggi, melainkan adanya pola pembelian lintas-varian dalam satu koleksi.

Selain aturan tiga item, pasangan varian **Pink** dan **Green** juga menunjukkan asosiasi dengan nilai lift yang tinggi. Aturan **Pink → Green** memiliki support 3,14% (633 invoice), confidence 82,64%, dan lift 16,3939. Arah sebaliknya, **Green → Pink**, memiliki support yang sama, confidence 62,36%, dan lift 16,3939. Hubungan ini memperkuat indikasi bahwa dua varian tersebut kerap hadir dalam invoice yang sama.

### 2.8 Aturan Lain yang Diperoleh

Notebook juga menyoroti beberapa pasangan produk dengan lift tinggi.

| Antecedent | Consequent | Invoice | Support | Confidence | Lift |
|---|---|---|---|---|---|
| Gardeners Kneeling Pad Keep Calm | Gardeners Kneeling Pad Cup of Tea | 546 | 2,71% | 59,80% | 15,8864 |
| Spaceboy Lunch Box | Dolly Girl Lunch Box | 538 | 2,67% | 59,78% | 14,1610 |
| Jumbo Bag Pears | Jumbo Bag Apples | 406 | 2,02% | 68,24% | 14,0489 |

Pola tersebut dapat diinterpretasikan secara deskriptif sebagai berikut:

- Dua desain **Gardeners Kneeling Pad** tampak sering dibeli bersama. Aturan arah sebaliknya juga menunjukkan asosiasi positif, dengan confidence 72,03%. Ini dapat mengindikasikan pembelian beberapa desain dalam kategori yang sama.
- **Spaceboy Lunch Box** dan **Dolly Girl Lunch Box** memiliki hubungan dua arah. Confidence masing-masing adalah 59,78% dan 63,29%. Keduanya layak diuji sebagai rekomendasi silang dalam kategori kotak makan anak.
- Pembeli **Jumbo Bag Pears** relatif sering juga membeli **Jumbo Bag Apples**. Pola ini konsisten dengan kemungkinan pelanggan memilih lebih dari satu desain dalam satu jenis tas.

Penjelasan mengenai alasan produk-produk tersebut dibeli secara bersamaan tidak dapat dipastikan dari analisis ini. Notebook hanya menunjukkan ko-kemunculan produk dalam invoice dan tidak mengamati motivasi pembelian.

### 2.9 Implikasi Hasil Analisis

**Bundling berbasis koleksi.**

Salah satu tindak lanjut yang dapat diuji adalah bundling tiga varian **Regency Teacup and Saucer**. Ketiga varian dapat ditampilkan sebagai satu koleksi, baik melalui halaman produk koleksi, rekomendasi produk terkait, maupun paket hadiah. Hasil association rule memberi dasar bahwa varian-varian tersebut memiliki kecenderungan muncul bersama dalam invoice.

**Rekomendasi kontekstual di keranjang.**

Varian **Green Regency Teacup and Saucer** dapat dipertimbangkan sebagai salah satu rekomendasi ketika keranjang berisi varian **Pink** dan **Roses**. Dasarnya adalah confidence 90,48% untuk aturan `Pink + Roses -> Green`. Rekomendasi ini lebih kontekstual daripada menampilkan produk secara acak karena didasarkan pada kombinasi item yang sudah ada di keranjang.

**Pengelompokan display dan cross-selling kategori.**

Pasangan **Gardeners Kneeling Pad**, **Spaceboy** dan **Dolly Girl Lunch Box**, serta **Jumbo Bag Pears** dan **Jumbo Bag Apples** dapat menjadi kandidat pengujian penempatan produk berdekatan atau modul “sering dibeli bersama”. Untuk pasangan yang memiliki aturan dua arah, rekomendasi sebaiknya tidak bergantung pada satu produk pemicu saja.

**Validasi melalui eksperimen.**

Association rule belum mengukur dampak strategi terhadap penjualan. Karena itu, rekomendasi di atas sebaiknya diperlakukan sebagai kandidat eksperimen. Beberapa metrik lanjutan yang dapat dipantau adalah tingkat klik rekomendasi, conversion rate, nilai rata-rata keranjang, jumlah item per invoice, dan ketersediaan stok. Perbandingan sebelum-sesudah atau eksperimen A/B diperlukan sebelum menyimpulkan bahwa bundling benar-benar meningkatkan pendapatan.

### 2.10 Keterbatasan Analisis

Beberapa batasan penting perlu dipertimbangkan saat membaca hasil:

1. **Asosiasi bukan kausalitas.** Lift dan confidence menunjukkan keterkaitan statistik antaritem, bukan bukti bahwa pembelian satu produk menyebabkan pembelian produk lain.
2. **Periode data historis.** Transaksi yang dianalisis berasal dari Desember 2010 hingga Desember 2011. Preferensi pada periode tersebut belum tentu mewakili perilaku pembelian saat ini.
3. **Analisis pada level invoice.** Hasil menggambarkan produk yang muncul bersama dalam satu invoice. Notebook tidak menganalisis pola pembelian berulang pada level pelanggan atau segmentasi pelanggan.
4. **CustomerID yang hilang.** Sebanyak 24,93% nilai `CustomerID` kosong. Hal ini tidak menghalangi analisis invoice, tetapi membatasi analisis lanjutan yang membutuhkan identitas pelanggan secara konsisten.
5. **Informasi kuantitas tidak dipertahankan dalam basket.** Deduplikasi `InvoiceNo` dan `Description` membuat satu produk hanya dihitung sekali per invoice. Analisis tidak membedakan pembelian satu unit dan beberapa unit.
6. **Batas panjang itemset.** `max_len = 3` membatasi aturan pada gabungan maksimal tiga produk. Pola yang melibatkan empat produk atau lebih tidak dievaluasi.
7. **Ambang support.** Support minimum 2% membantu mengurangi jumlah aturan, tetapi pola niche yang jarang terjadi dapat tersaring meskipun mungkin bernilai bagi segmen tertentu.
8. **Tidak ada evaluasi dampak bisnis langsung.** Notebook tidak menghitung kenaikan omzet, margin, conversion rate, atau hasil eksperimen rekomendasi. Rekomendasi bisnis masih perlu diuji.

Selain itu, notebook berfokus pada tabel ringkasan dan aturan asosiasi. Walaupun beberapa pustaka visualisasi diimpor, output yang menjadi dasar laporan ini terutama berupa tabel, bukan hasil visualisasi EDA atau dashboard.

## 3 Kesimpulan

Analisis berhasil mengubah data transaksi mentah menjadi pola asosiasi produk yang dapat ditafsirkan untuk kebutuhan cross-selling. Setelah pembersihan dan pembentukan basket, terdapat 20.136 invoice dan 4.057 produk unik yang dianalisis. Penyesuaian minimum support dari 1% menjadi 2% membuat hasil lebih ringkas: jumlah aturan turun dari 741 menjadi 61 tanpa mengubah ambang confidence 0,5. Hasil utama menunjukkan adanya asosiasi antara tiga varian **Regency Teacup and Saucer**. Lift tertinggi mencapai 18,5516, sedangkan aturan **Pink + Roses -> Green** memiliki confidence 90,48%. Pola lain juga muncul pada desain **Gardeners Kneeling Pad**, kotak makan **Spaceboy** dan **Dolly Girl**, serta desain **Jumbo Bag**.

Dalam konteks bisnis, hasil ini dapat digunakan sebagai dasar awal untuk menguji bundling produk, rekomendasi berdasarkan isi keranjang, dan pengelompokan display. Namun, keputusan implementasi sebaiknya menunggu validasi melalui eksperimen dan metrik bisnis. Association rule digunakan untuk mengidentifikasi hubungan antarproduk. Metode ini tidak membuktikan sebab-akibat atau menjamin peningkatan penjualan.

Catatan sumber: angka, parameter, dan aturan yang disajikan dalam laporan ini diambil dari output `notebook(6).ipynb`. Persentase pengurangan dan perhitungan ringkasan lainnya dihitung berdasarkan angka yang ditampilkan dalam notebook.