ANALISIS PENGARUH SMOTE TERHADAP KINERJA DETEKSI FRAUD KARTU KREDIT

Pranaja Adyatma Budiman 5054251009

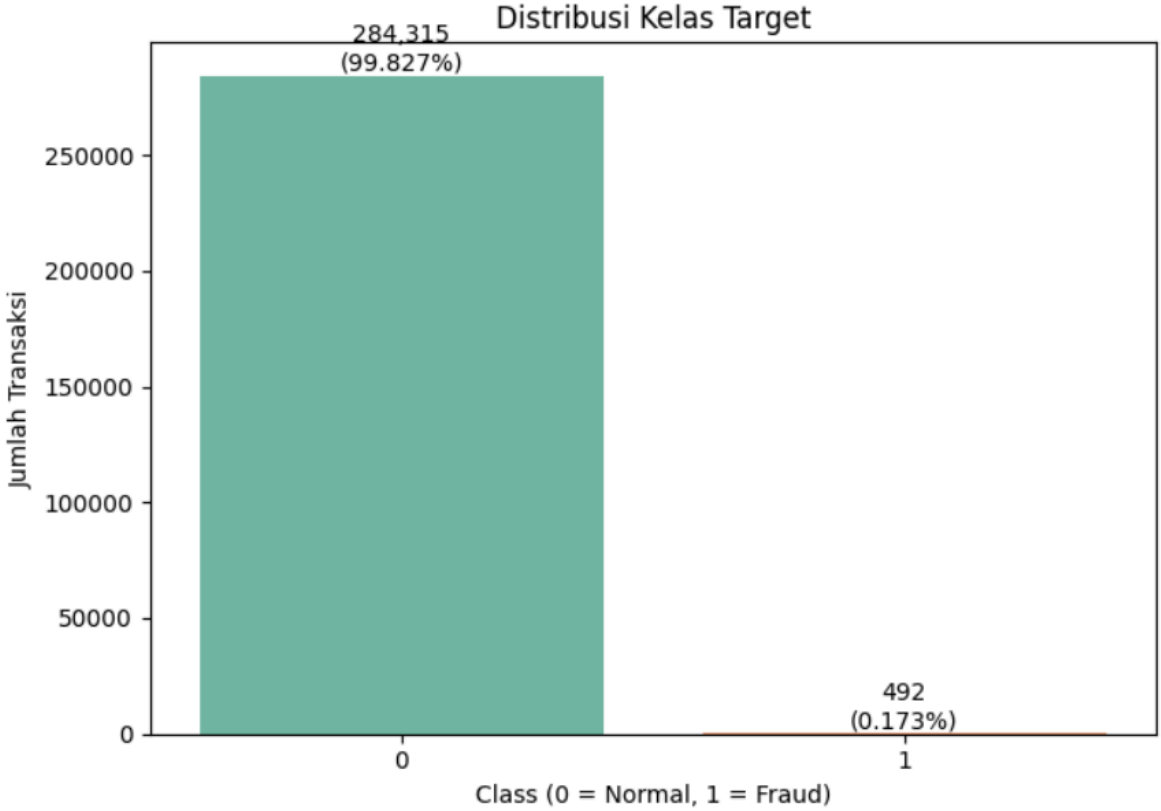
1. Pendahuluan

Deteksi transaksi kartu kredit yang terindikasi fraud merupakan masalah klasifikasi biner dengan distribusi kelas sangat tidak seimbang. Pada kondisi tersebut, akurasi keseluruhan berpotensi memberikan gambaran yang menyesatkan karena kelas transaksi normal sangat dominan. Eksperimen ini membandingkan pelatihan model dengan dan tanpa *Synthetic Minority Over-sampling Technique* (SMOTE), menggunakan LightGBM, Random Forest, serta kombinasi probabilitas keduanya (*weighted blending*). Seluruh angka yang dilaporkan diambil dari keluaran notebook eksperimen.

2. Hasil dan Pembahasan

2.1. Distribusi Kelas Awal

Dataset memuat **284.807 transaksi**, terdiri atas 30 fitur numerik dan satu target `Class`. Label 0 menunjukkan transaksi normal, sedangkan label 1 menunjukkan fraud. Tidak ditemukan nilai hilang pada seluruh kolom, tetapi teridentifikasi 1.081 baris duplikat. Notebook tidak memperlihatkan penghapusan duplikat sebelum pembagian data, sehingga hal tersebut menjadi keterbatasan yang perlu dicatat.



Jumlah fraud hanya sekitar 0,173% dari seluruh transaksi, atau sekitar satu transaksi fraud untuk setiap 578 transaksi normal. Ketimpangan ini menjadi alasan utama pengujian

SMOTE. Model yang terlalu berorientasi pada kelas mayoritas dapat gagal mengidentifikasi transaksi fraud meskipun akurasi totalnya tampak tinggi.

2.2. Mengapa Accuracy Saja Tidak Cukup

Pada dataset ini, kelas normal mencakup 284.315 dari 284.807 transaksi (99,827%), sedangkan kelas fraud hanya 492 transaksi (0,173%). Ketimpangan tersebut menyebabkan **accuracy** berpotensi menyesatkan apabila digunakan sebagai satu-satunya ukuran keberhasilan model. Sebagai ilustrasi, model yang selalu memprediksi seluruh transaksi sebagai normal akan memperoleh accuracy sebesar 99,827%, meskipun **tidak berhasil mendeteksi satu pun transaksi fraud** (recall fraud = 0%). Dengan kata lain, accuracy yang sangat tinggi belum tentu menunjukkan kemampuan deteksi fraud yang baik.

Hal ini terjadi karena accuracy menghitung proporsi seluruh prediksi yang benar, sehingga hasilnya didominasi oleh kelas normal yang jumlahnya jauh lebih besar. Dalam konteks deteksi fraud, kesalahan berupa transaksi fraud yang tidak terdeteksi (*false negative*) perlu mendapat perhatian khusus, sementara prediksi fraud yang ternyata normal (*false positive*) juga menimbulkan biaya pemeriksaan atau alarm palsu. Oleh karena itu, evaluasi perlu mempertimbangkan **recall** untuk melihat seberapa banyak fraud yang berhasil ditemukan, **precision** untuk menilai ketepatan alarm fraud, dan **F1-score** untuk menyeimbangkan kedua ukuran tersebut. **PR-AUC** juga penting karena menilai performa precision–recall pada berbagai threshold dan lebih informatif untuk kelas positif yang sangat jarang. Dengan demikian, pemilihan model pada eksperimen ini tidak didasarkan pada accuracy saja, melainkan terutama pada PR-AUC, precision, recall, dan F1-score.

2.3. Pendekatan Penanganan Class Imbalance

Data dibagi secara *stratified* dengan proporsi 60% training, 20% validation, dan 20% testing (`random_state=42`). Pemisahan stratified mempertahankan proporsi kelas pada masing-masing subset. SMOTE hanya diterapkan pada data training, sedangkan validation dan test tetap menggunakan distribusi asli agar evaluasi mencerminkan kondisi data yang tidak seimbang.

Subset	Normal	Fraud	Total
Training awal	170.589	295	170.884
Training SMOTE	170.589	170.589	341.178
Validation	56.863	98	56.961
Testing	56.863	99	56.962

Tabel 1: Distribusi kelas setelah pemisahan dan oversampling pada training.

SMOTE (`random_state=42`) membangkitkan sampel sintetis kelas fraud berdasarkan kedekatan antarsampel minoritas hingga jumlahnya setara dengan kelas normal. Dengan demikian, jumlah fraud dalam data training meningkat dari 295 menjadi 170.589, sedangkan jumlah kelas normal tidak berubah. Sebagai pembanding, model tanpa SMOTE dilatih langsung menggunakan training asli. Penggunaan parameter model dan subset evaluasi yang sama memungkinkan perbandingan dampak oversampling secara lebih terkendali.

Dua algoritma yang diuji ialah LightGBM (`n_estimators=350`, `learning_rate=0.05`, `num_leaves=31`) dan Random Forest (`n_estimators=200`, `max_depth=15`, `min_samples_leaf=2`). Selain model tunggal, probabilitas prediksi digabungkan melalui *weighted blending*. Bobot

LightGBM diuji dari 0 sampai 1 dengan interval 0,05, dan dipilih berdasarkan PR-AUC pada validation. Bobot terbaik untuk pendekatan SMOTE adalah 0,90 LightGBM dan 0,10 Random Forest, sedangkan tanpa SMOTE bobot terbaik adalah 0,00 LightGBM dan 1,00 Random Forest. Karena itu, **Blend Tanpa SMOTE secara efektif sama dengan Random Forest Tanpa SMOTE**.

2.4. Metrik Evaluasi

Eksperimen menggunakan **PR-AUC** (*average precision*), **ROC-AUC**, **precision**, **recall**, dan **F1-score** untuk kelas fraud. PR-AUC menjadi ukuran utama untuk mengevaluasi kualitas pemeringkatan prediksi fraud pada kelas positif yang sangat langka. Precision menunjukkan proporsi prediksi fraud yang benar, recall menunjukkan proporsi fraud aktual yang terdeteksi, dan F1-score menyeimbangkan keduanya. ROC-AUC mengukur kemampuan model membedakan kedua kelas pada berbagai ambang keputusan.

Pada perbandingan validation awal, precision, recall, dan F1-score dihitung dengan threshold tetap 0,5. Selanjutnya, setiap model memperoleh threshold optimal berdasarkan F1-score pada validation (kandidat 0,01 sampai 0,99 dengan interval 0,01). Threshold dan bobot tersebut digunakan kembali pada test tanpa optimasi tambahan.

2.5. Hasil pada Validation Set

Model	PR-AUC	Recall	F1
Blend SMOTE	0,8170	0,7959	0,7959
LGBM SMOTE	0,8157	0,7959	0,8000
RF SMOTE	0,7993	0,7857	0,7586
Blend tanpa SMOTE	0,8026	0,7449	0,8295
RF tanpa SMOTE	0,8026	0,7449	0,8295
LGBM tanpa SMOTE	0,3140	0,6122	0,3235

Tabel 2: Perbandingan metrik validation pada threshold tetap 0,5.

Pada validation, Blend SMOTE memperoleh PR-AUC tertinggi (0,8170), melampaui Blend Tanpa SMOTE (0,8026) sebesar 0,0144. Namun, pada threshold 0,5, F1 Blend Tanpa SMOTE (0,8295) justru lebih tinggi daripada Blend SMOTE (0,7959). Hal ini menunjukkan bahwa kemampuan mengurutkan transaksi berdasarkan risiko fraud tidak selalu sejalan dengan kualitas klasifikasi pada satu threshold tertentu. LightGBM tanpa SMOTE memiliki hasil paling rendah dalam eksperimen ini, tetapi hasil tersebut tidak dapat digeneralisasikan ke semua konfigurasi LightGBM.

Setelah optimasi threshold berdasarkan F1 validation, Blend SMOTE menggunakan threshold 0,75 dengan F1 validation 0,8342; RF/Blend Tanpa SMOTE menggunakan threshold 0,36 dengan F1 0,8324; LGBM SMOTE menggunakan threshold 0,89 dengan F1 0,8306; dan RF SMOTE menggunakan threshold 0,85 dengan F1 0,8090. Perubahan threshold memengaruhi trade-off antara precision dan recall tanpa mengubah PR-AUC.

2.6. Evaluasi Akhir pada Test Set

Model	PR-AUC	Precision	Recall	F1
Blend SMOTE	0,8751	0,8947	0,8586	0,8763
RF tanpa SMOTE	0,8745	0,9121	0,8384	0,8737
Blend tanpa SMOTE	0,8745	0,9121	0,8384	0,8737
RF SMOTE	0,8681	0,9070	0,7879	0,8432
LGBM SMOTE	0,8544	0,9032	0,8485	0,8750
LGBM tanpa SMOTE	0,4097	0,3568	0,6667	0,4648

Tabel 3: Hasil test set menggunakan threshold hasil optimasi validation.

Model	ROC-AUC	Threshold
Blend SMOTE	0,9767	0,75
RF tanpa SMOTE	0,9734	0,36
Blend tanpa SMOTE	0,9734	0,36
RF SMOTE	0,9762	0,85
LGBM SMOTE	0,9795	0,89
LGBM tanpa SMOTE	0,7911	0,99

Tabel 4: ROC-AUC dan threshold keputusan pada test set.

Blend SMOTE menghasilkan PR-AUC tertinggi sebesar 0,8751 dan F1-score tertinggi sebesar 0,8763. Recall 0,8586 menunjukkan bahwa model ini mendeteksi sekitar 85,86% dari 99 transaksi fraud pada test, sedangkan precision 0,8947 menunjukkan bahwa sekitar 89,47% transaksi yang diprediksi fraud memang termasuk fraud. Dibandingkan RF tanpa SMOTE, Blend SMOTE meningkatkan recall sebesar sekitar 2,02 poin persentase, tetapi precision turun sekitar 1,74 poin persentase. Dengan demikian, pilihan metode berkaitan dengan prioritas mendeteksi fraud sebanyak mungkin atau menekan alarm palsu.

Perbedaan PR-AUC antara Blend SMOTE (0,8751) dan RF tanpa SMOTE (0,8745) hanya sekitar 0,0006, sementara perbedaan F1 sebesar 0,0026. Selisih tersebut sangat kecil dan belum cukup untuk menyimpulkan bahwa SMOTE secara konsisten lebih unggul. Selain itu, RF SMOTE menghasilkan recall 0,7879, lebih rendah daripada RF tanpa SMOTE (0,8384); sehingga manfaat oversampling juga berbeda menurut model. LGBM SMOTE menunjukkan peningkatan besar dibandingkan LGBM tanpa SMOTE dalam konfigurasi eksperimen ini. ROC-AUC tertinggi justru diperoleh LGBM SMOTE (0,9795), memperlihatkan bahwa peringkat model dapat berubah sesuai metrik yang diprioritaskan.

3. Kesimpulan

Dataset memiliki ketimpangan kelas yang ekstrem, dengan hanya 492 fraud dari 284.807 transaksi (0,173%). SMOTE berhasil menyeimbangkan training dengan meningkatkan jumlah contoh fraud dari 295 menjadi 170.589 tanpa mengubah validation dan test. Pada eksperimen ini, Blend SMOTE memberikan hasil test terbaik menurut PR-AUC (0,8751) dan F1-score (0,8763), tetapi keunggulannya atas RF tanpa SMOTE sangat tipis. RF tanpa SMOTE justru memberikan precision lebih tinggi (0,9121 dibandingkan 0,8947), sementara Blend SMOTE memiliki recall lebih tinggi (0,8586 dibandingkan 0,8384). Dengan demikian, SMOTE dapat membantu, khususnya pada konfigurasi LightGBM yang diuji, tetapi tidak

otomatis meningkatkan setiap model maupun setiap metrik. Pemilihan pendekatan akhir perlu mempertimbangkan trade-off precision–recall dan dikonfirmasi dengan validasi yang lebih stabil.